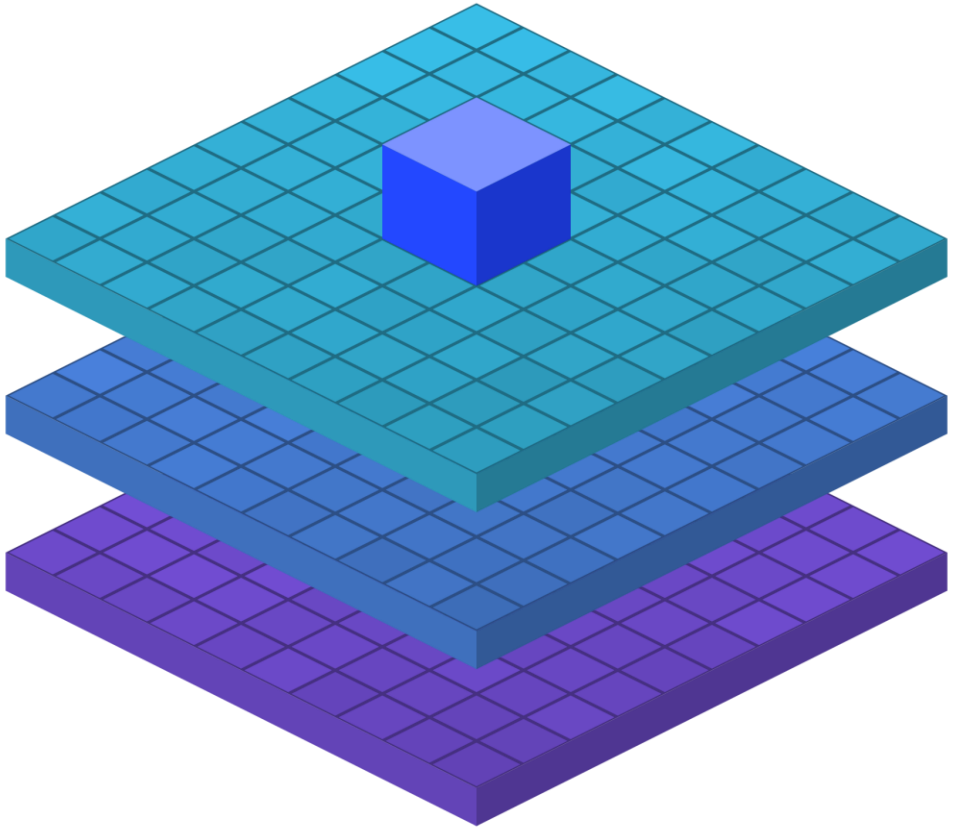
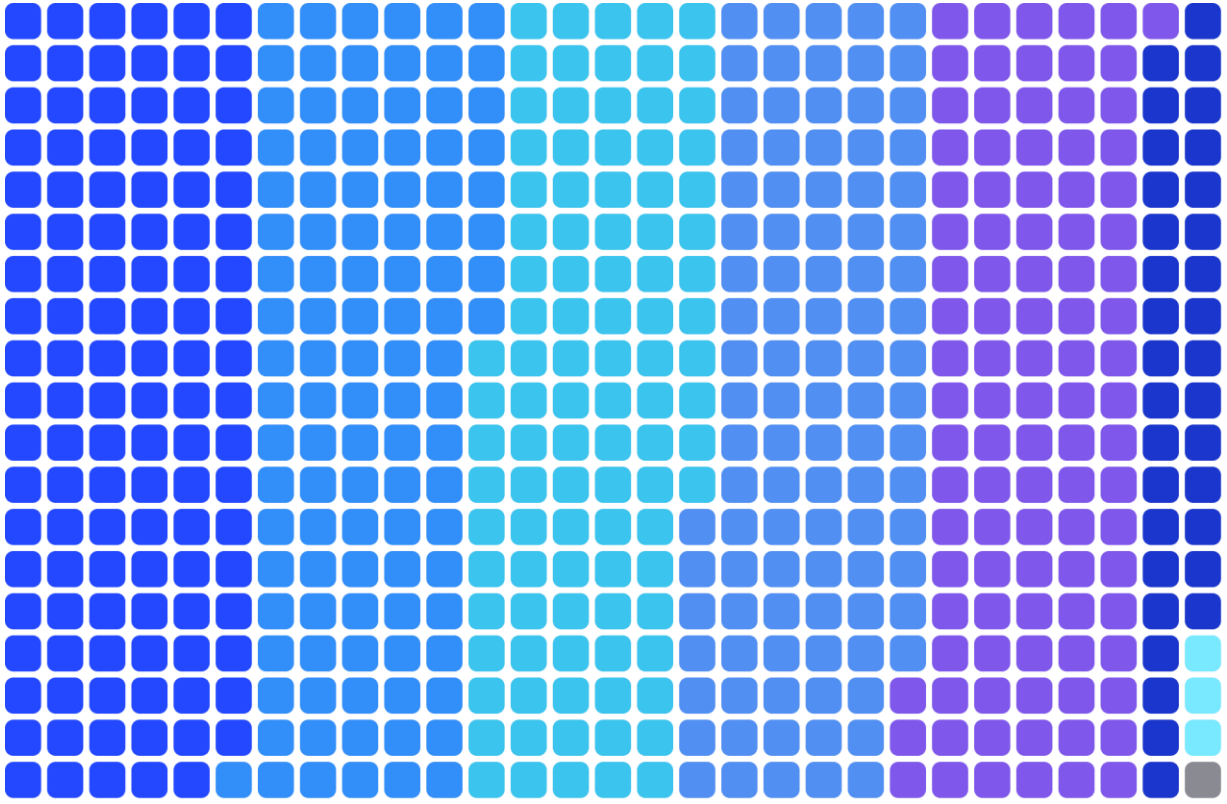
datum

Модель данных Capibara:
от корзины до выкупа



Хакатон, кейс «Модель маркетплейса»

550 759 строк *и все текстом*

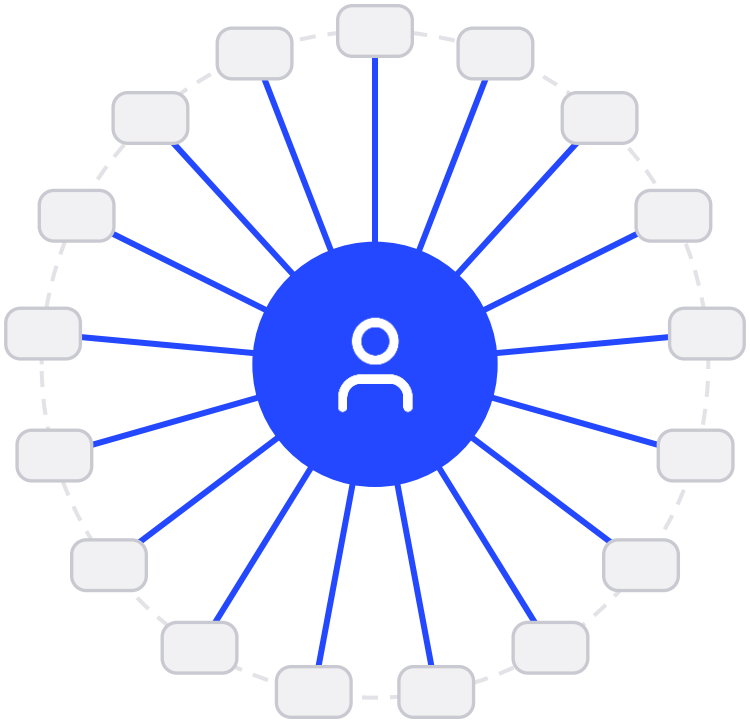


order_items	112 650
order_payments	103 886
orders	99 441
order_reviews	99 224
customers	99 441
products	32 951
sellers	3 095
category_translation	71

1 клетка = 1 000 строк. Даты, суммы и оценки приехали строками, каждую колонку проверили скриптами.

datum

Анкета не равна *человеку*

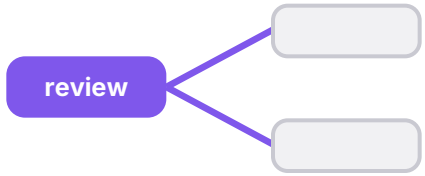


до 17 анкет у одного человека

~~99 441~~ → **96 096**

`customer_id`: анкета на каждый заказ

`customer_unique_id`: человек



789

отзывов висят сразу на нескольких заказах

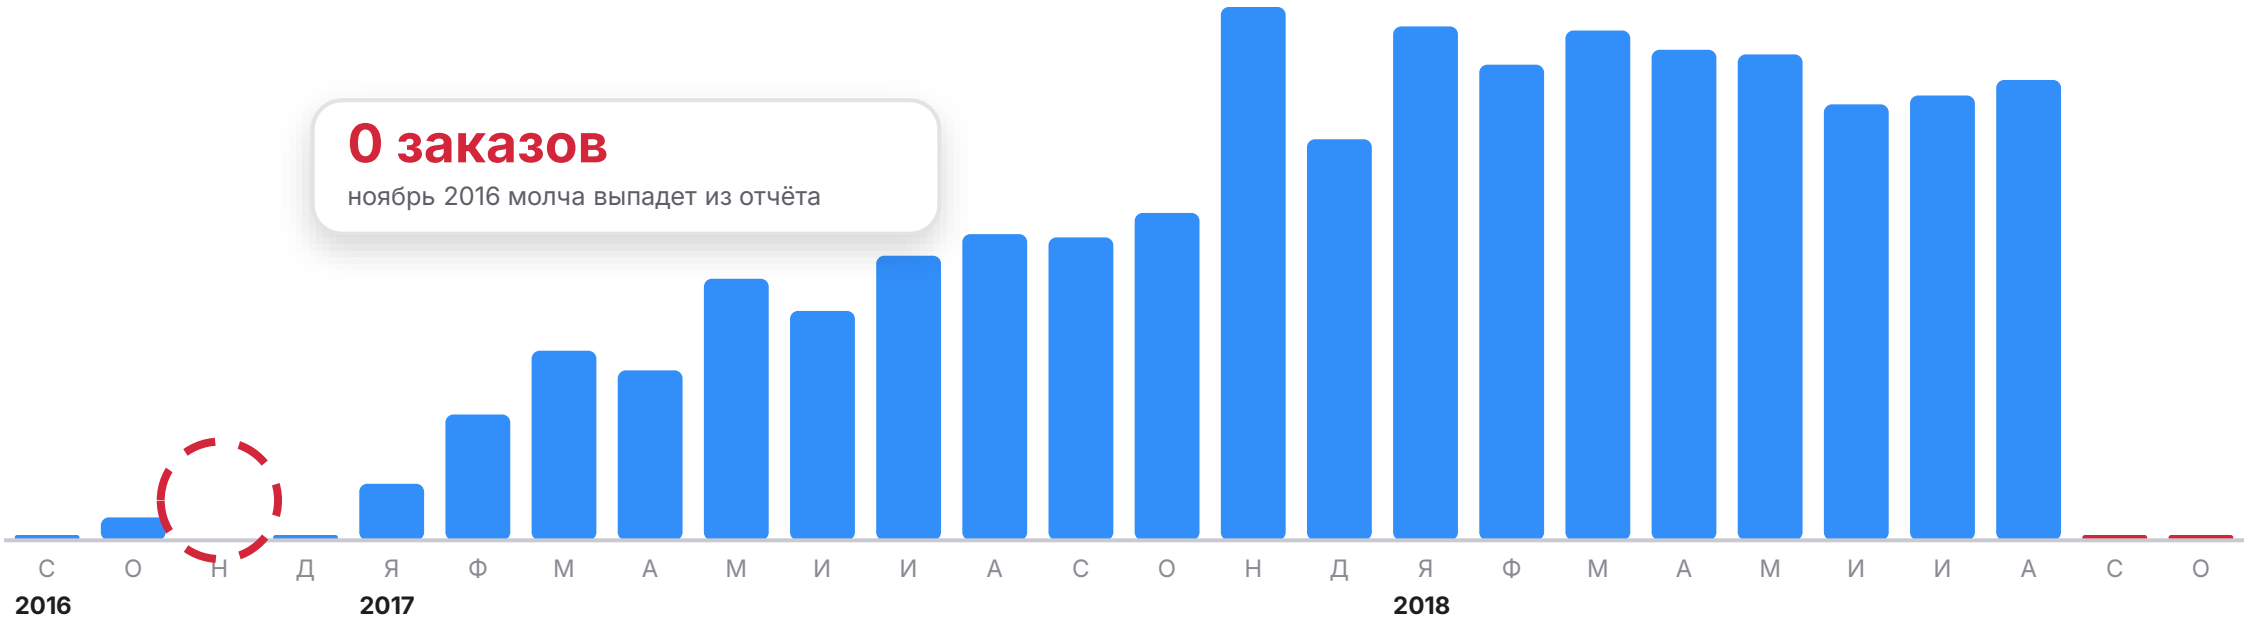


`order_item_id`

номер строки внутри заказа, а не ключ

datum

Пропуски *и потери*



610
товаров без категории

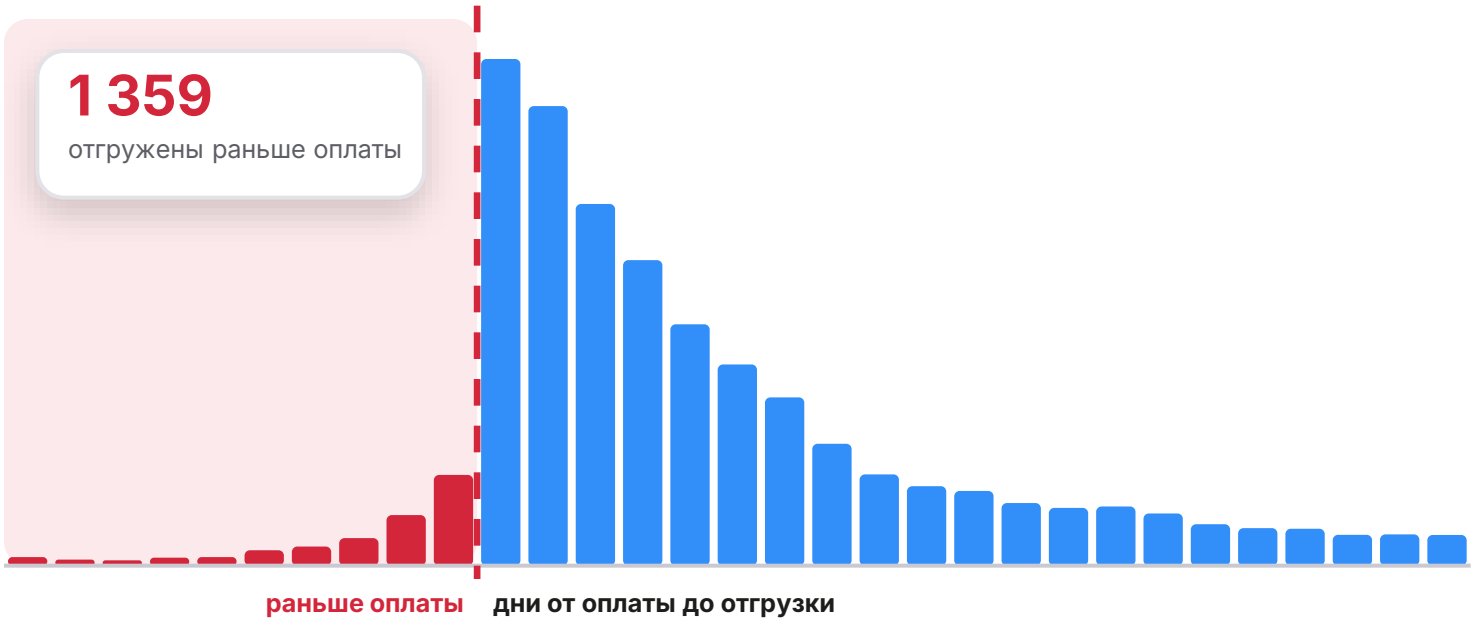
775
заказов без позиций: unavailable и canceled

170 726,63
R$ выручки на товарах без категории

73 ≠ 71
категорий в товарах и в переводах

datum

Хронология *и грязь*



23

вручены раньше отгрузки

6

отменённых с датой вручения

1 139

заказов: платежи не бьются с позициями

`auriflama/sp`

`rio de janeiro \ rio de janeiro`

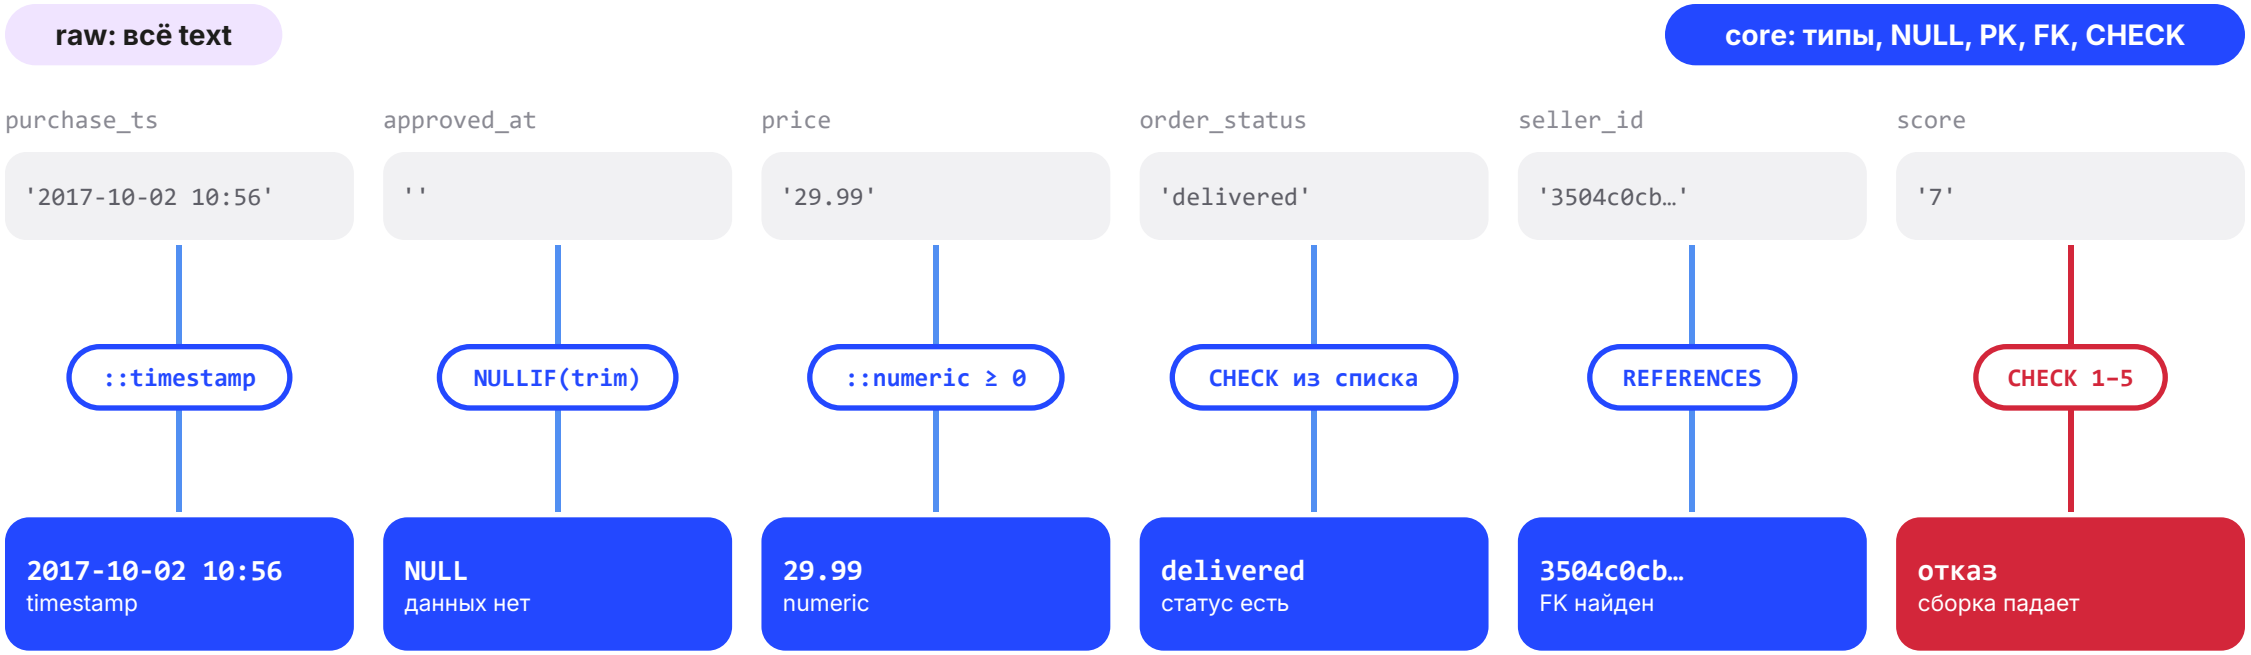
`04482255`

611

написаний городов, индекс вместо города

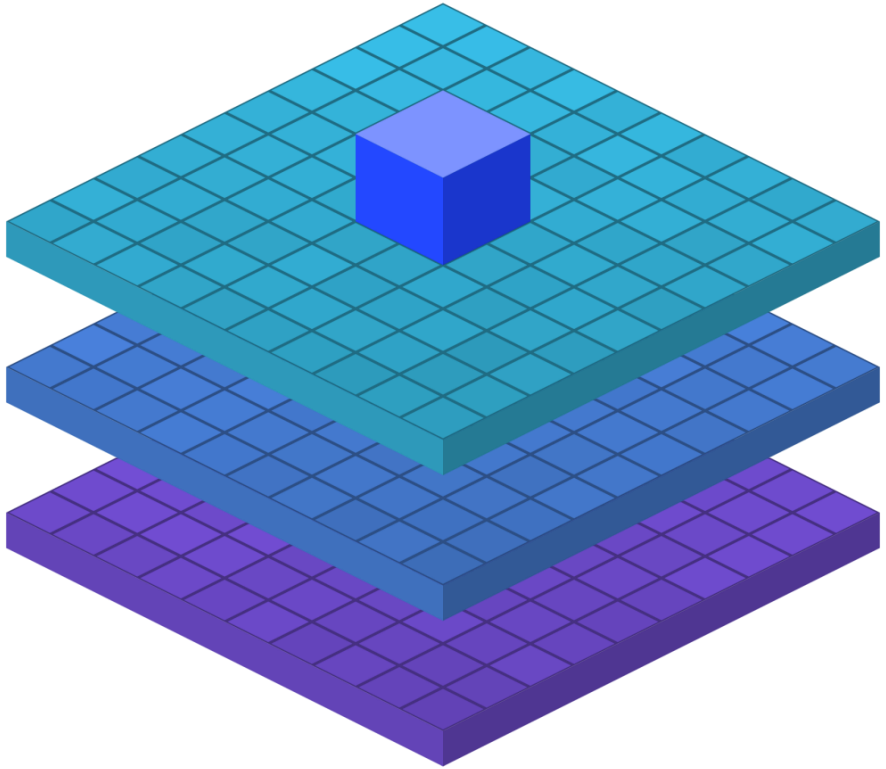
Вывод: источникам доверять нельзя. Проверки живут в модели, а не в голове аналитика.

Как решили: *правила переноса*



Один скрипт **`build_core.sql`** с нуля, DROP SCHEMA и BEGIN … COMMIT: наполовину собранной модели не бывает

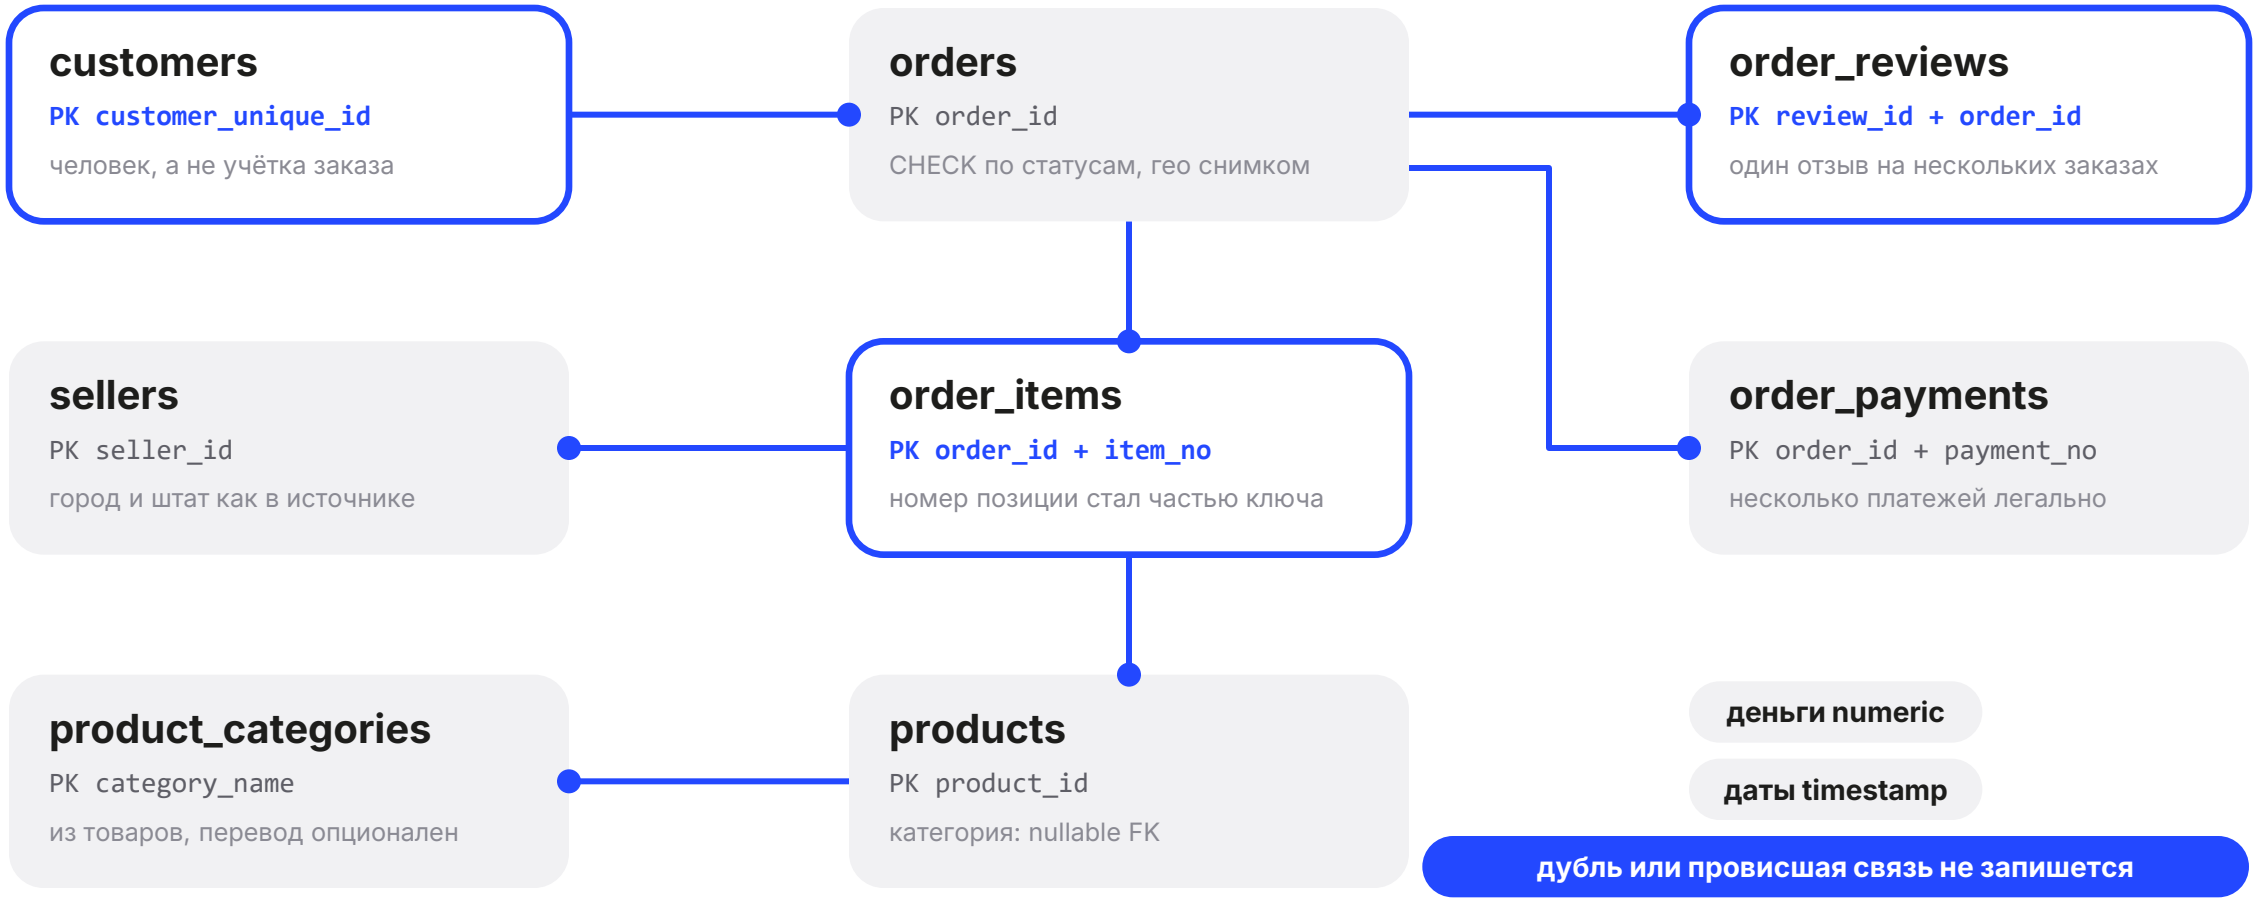
Три слоя, *как в нашем знаке*



- **ответы** считаются из core
- **mart** витрины под задачу: исполнение заказа
- **core** модель: типы, ключи, связи, дедупликация
- **raw** как приехало, только читаем

`build_core.sql` → `build_mart.sql` → `build_dashboard.py`

Схема core: *ключ это решение*

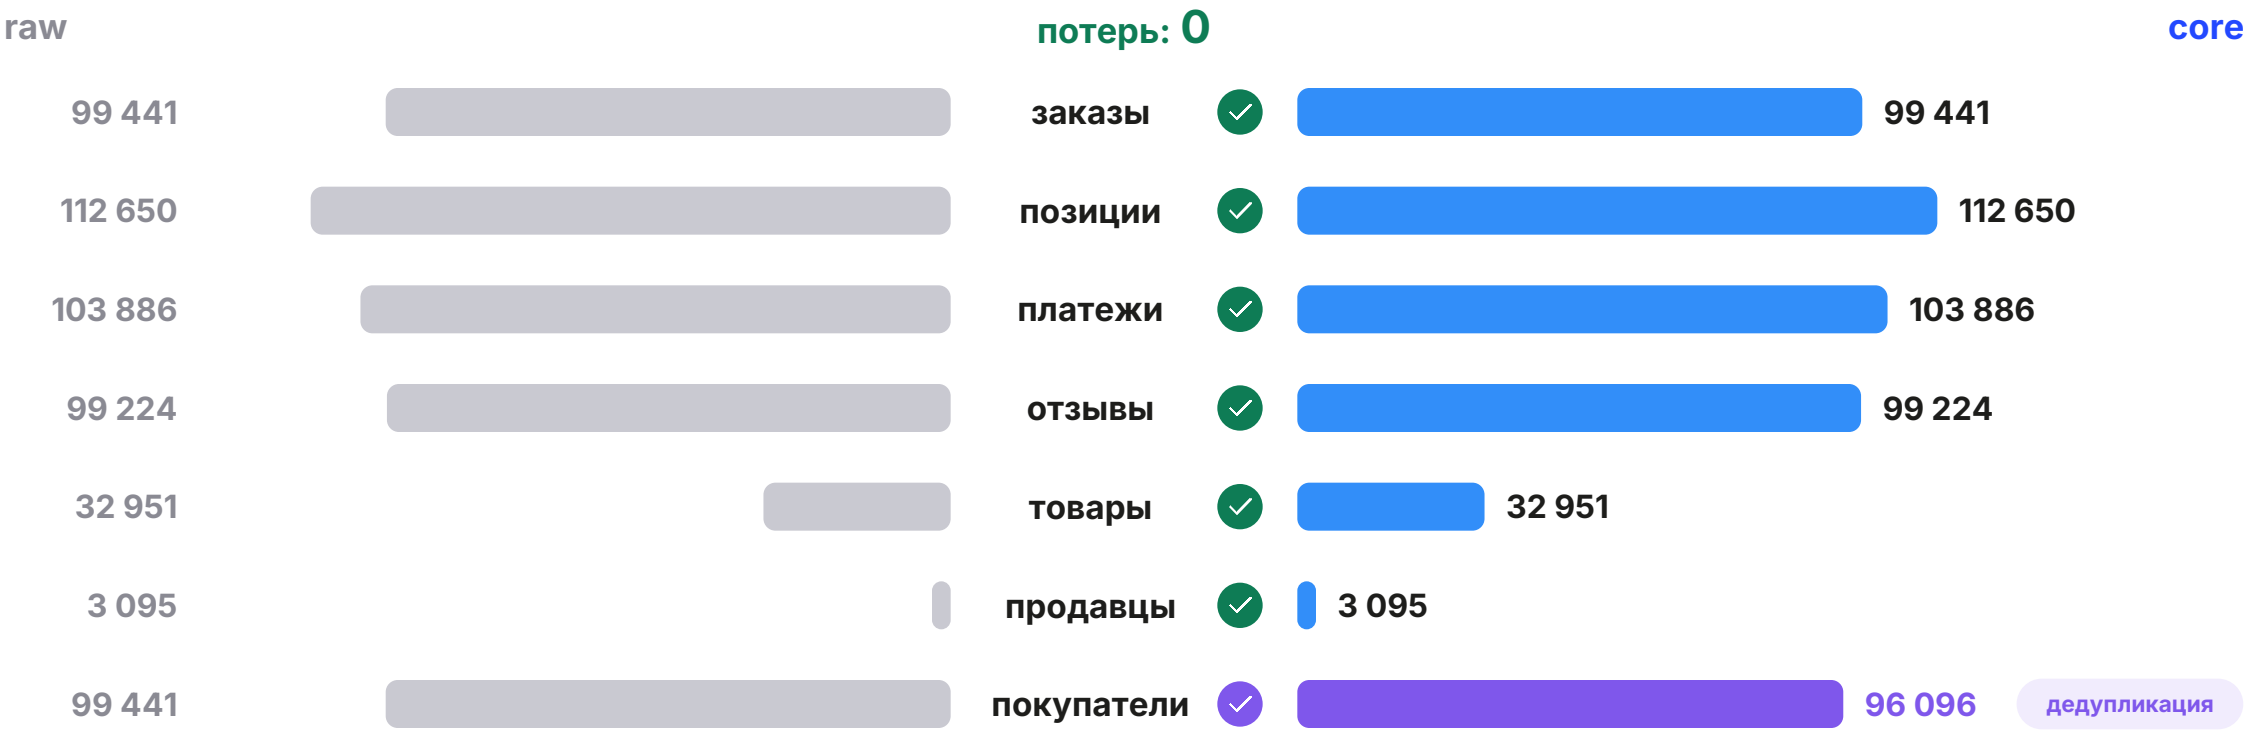


Почему *именно так*

	наивно		в модели	потеря	решение
Покупатель	~~99 441~~	→	96 096	3 345 дублей	customer_unique_id, повторных 3,12% вместо 0
География	~~адрес сейчас~~	→	адрес в заказе	250 переездов	снимок в заказе, регионы не плывут
Категории	~~71~~	→	74	−3 категории	справочник из товаров, перевод опционален
Без категории	~~13 050 771,48~~	→	13 221 498,11	−170 726,63	отдельная строка, сумма сходится
Заказы в отчётах	~~98 666~~	→	99 441	−775 заказов	LEFT JOIN, где пары может не быть

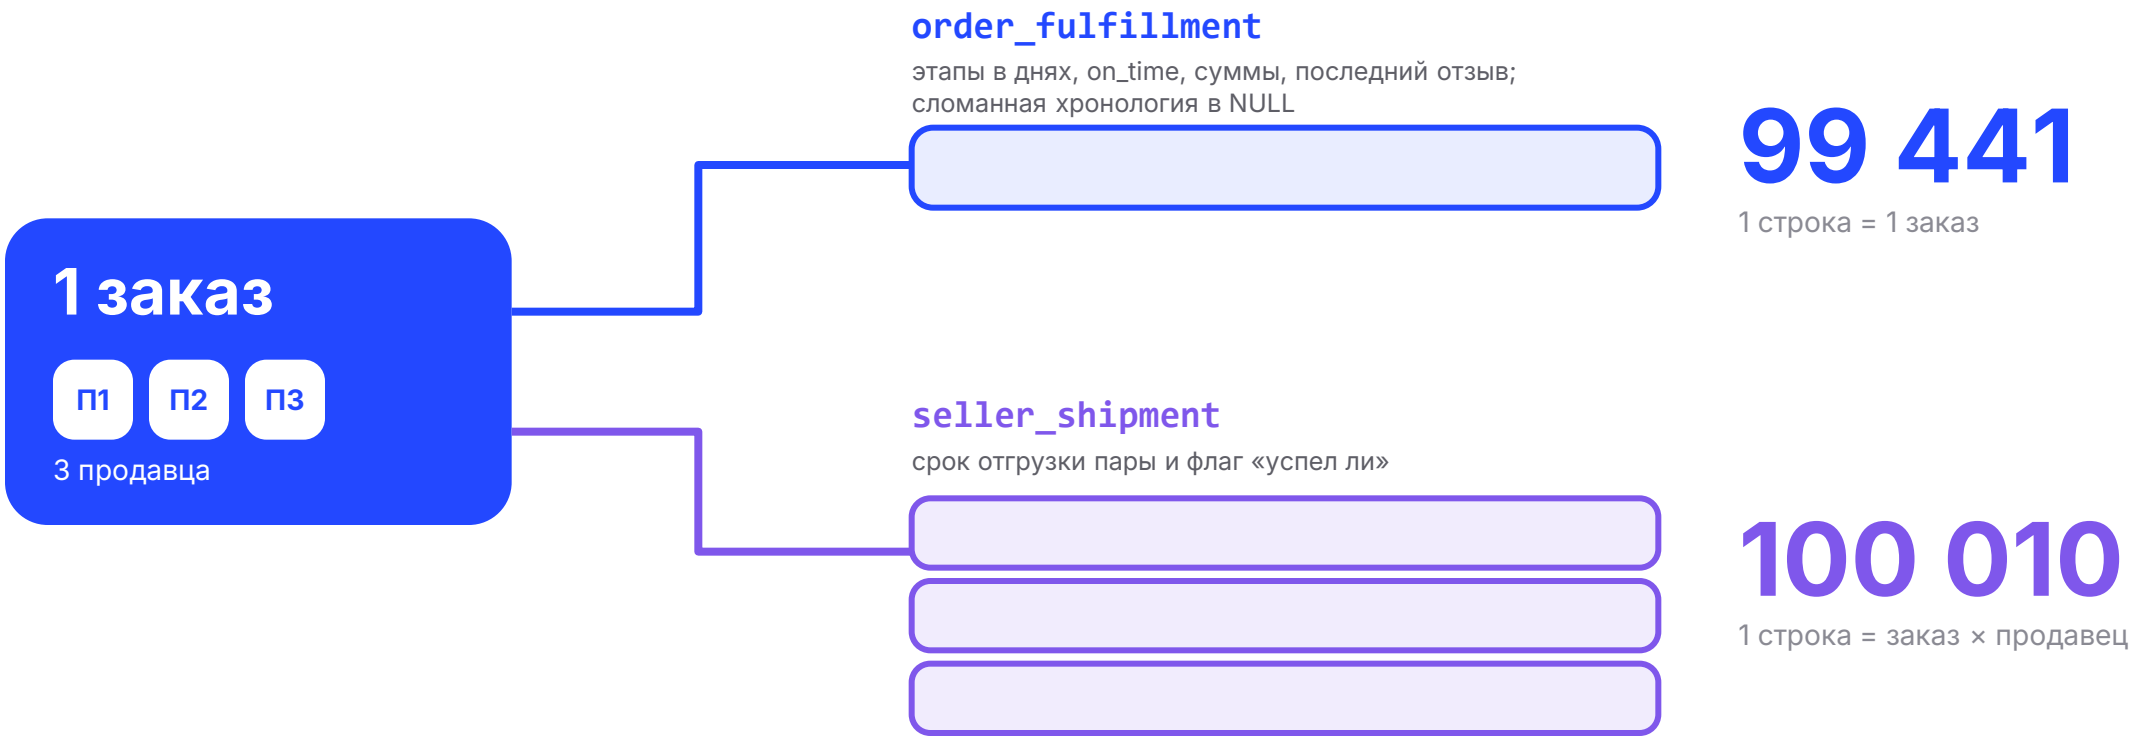
datum

Ничего *не потеряли*



`RAISE EXCEPTION` витрины: число строк, пары заказ и продавец, сумма денег. Расхождение валит сборку, а не молчит

Витрины: *один SELECT без join*

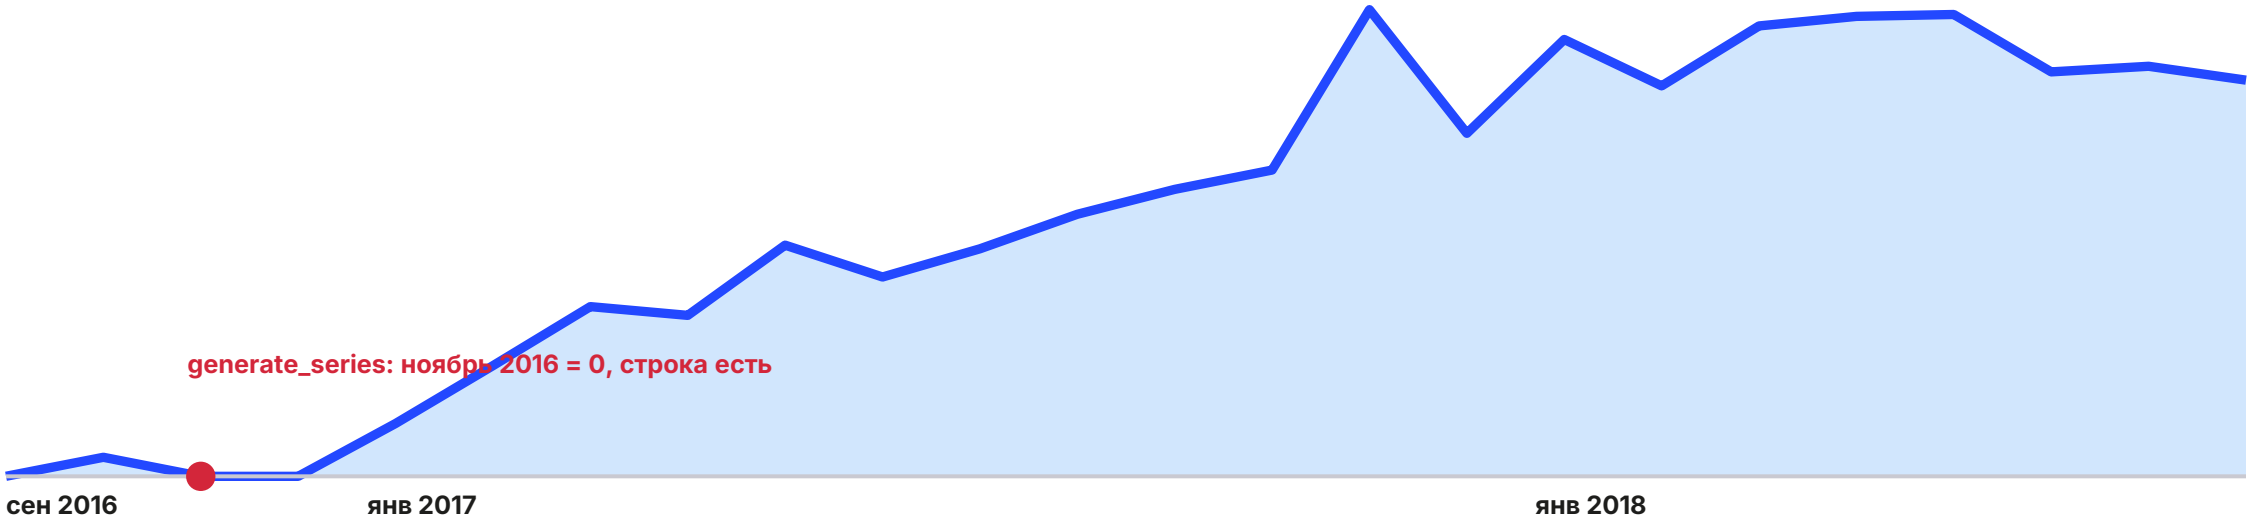


⚠ **is_single_seller:** дата отгрузки в источнике одна на заказ, поэтому рейтинг продавца честен только для заказов с одним продавцом

Блок A: *все пять контролей сошлись*

13 221 498,11

выручка за 24 месяца, R$, товары без доставки по доставленным заказам



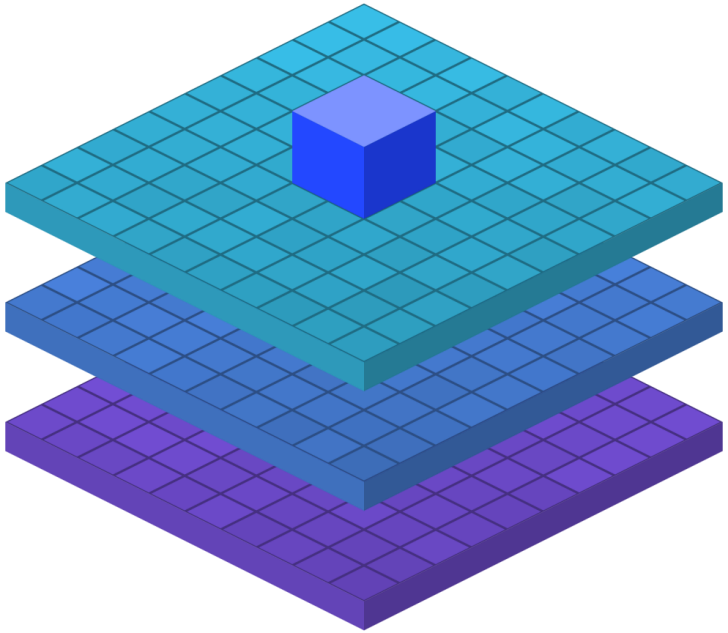
226 987,93
топ-продавец из Гуарибы: выручка от позиций

159,88
средний чек: заказ, потом среднее

96 096 · 3,12%
покупателей по customer_unique_id

74
категории с «(без категории)»

datum



Готовы к вашим *вопросам*

Одна модель, одна цифра для всех